

a4

(a)-(d)

```
return F.conv1d(input, weight, bias, self.stride,
torch.Size([2, 5, 2])
enc_hiddens Sanity Checks Passed!
dec_init_state[0] Sanity Checks Passed!
dec_init_state[1] Sanity Checks Passed!
-----
All Sanity Checks Passed for Question 1d: Encode!
-----
```

还是stanford好,有指导有参考,CMU的简直了,给你一大堆文件你自己写去吧.花了几小时写这几题,受益匪浅. LSTM先让你用了,然后你再去了解原理,这样反而是更好的,我相信我会在接下来更好的理解LSTM的机制.

(f)

这个确实不容易,尤其是有很多陌生知识的时候,收获很大,不过每走一步可能回顾过去写的代码,因为变量和函数以及文档太多了.

(e)

e被step的返回值卡住卡了半天.

```
> -----
Running Sanity Check for Question 1e: Decode
-----
torch.Size([23, 5, 2])
combined_outputs Sanity Checks Passed!
-----
All Sanity Checks Passed for Question 1e: Decode!
-----
(myhuggingface) program_machine@ChangzydeMacBook-Pro student %
```

(g)

First explain (in around three sentences) what effect the masks have on the entire attention computation. Then explain (in one or two sentences) why it is necessary to use the masks in this way. 使用mask的原因就是因为输入需要使用padding吧,但是padding的部分不参与计算,所以具体计算的时候就要mask掉.

GPT的回答:掩码在注意力计算中的作用是选择性地遮蔽序列的某些元素,以防止其影响网络输出.这有助于防止过度拟合和提高泛化性能.使用这种方式使用掩码是必要的,以确保模型不会过于关注无关信息,导致在未见数据上表现不佳.通过选择性地遮蔽元素,模型可以将注意力集中在输入序列的最重要部分,从而更有效地学习.

说明我们的理解是偏差不大的.

上面就是编码工作的全部,训练的话就再说吧.

(i) (4 points) (written) In class, we learned about dot product attention, multiplicative attention, and additive attention.

As a reminder, dot product attention is $e_{t,i} = s^T t_i h_i$, multiplicative attention is $e_{t,i} = s^T t_i W h_i$, and additive attention is $e_{t,i} = v^T \tanh(W_1 h_i + W_2 s)$.

i. (2 points) Explain one advantage and one disadvantage of dot product attention compared to multiplicative attention.

意思是点乘注意力和矩阵乘注意力相比,好坏处之一.

相对于乘法注意力, 点积注意力的一个优点是计算速度更快, 因为其计算方法较为简单。同时, 点积注意力能够有效地捕捉到输入序列中元素之间的相关性, 对于一些任务可能会有更好的表现。缺点在于, 点积操作不具备缩放性, 当向量维度较高时, 点积的值通常很大, 可能会导致模型训练不稳定或梯度消失问题。此外, 点积操作还需要将输入向量标准化, 这也会增加计算代价。

ii. (2 points) Explain one advantage and one disadvantage of additive attention compared to multiplicative attention.

下面是加性注意力和矩阵乘注意力相比的好坏处之一.

相对于乘法注意力, 加法注意力的一个优点是计算速度快, 因为其计算过程更简单。与此同时, 乘法注意力往往能够更好地表现输入序列元素之间的相关性, 对于一些计算任务来说可能会有更好的表现。缺点在于, 在处理长序列时, 由于加法过程不能捕捉到序列中元素之间的交互作用, 因此它的表示能力有限, 可能无法捕捉到整个序列的重要信息。

之前由于怕苦怕难和时间长等等原因不敢迈出这训练的第一步,但还是怎么说呢,这一步都不敢迈出去,怎么谈去做别的实验什么的.这个NMT整体是个很好的学习工具,把它的思想学到了比你读好几本书,看多少门课都有用!加油!

```
Terminal Local (4) × Local × Local (2) × + v
epoch 1, iter 280, avg. loss 144.77, avg. ppl 296.05 cum. examples 8960, speed 296.36 words/sec, time elapsed 674.42 sec
epoch 1, iter 290, avg. loss 147.63, avg. ppl 307.51 cum. examples 9280, speed 334.72 words/sec, time elapsed 699.06 sec
epoch 1, iter 300, avg. loss 147.42, avg. ppl 276.31 cum. examples 9600, speed 281.27 words/sec, time elapsed 728.89 sec
epoch 1, iter 310, avg. loss 147.00, avg. ppl 281.40 cum. examples 9920, speed 312.37 words/sec, time elapsed 755.60 sec
epoch 1, iter 320, avg. loss 143.35, avg. ppl 288.49 cum. examples 10240, speed 326.33 words/sec, time elapsed 780.41 sec
epoch 1, iter 330, avg. loss 147.20, avg. ppl 276.86 cum. examples 10560, speed 272.08 words/sec, time elapsed 811.20 sec
epoch 1, iter 340, avg. loss 139.72, avg. ppl 255.63 cum. examples 10880, speed 275.24 words/sec, time elapsed 840.50 sec
epoch 1, iter 350, avg. loss 145.37, avg. ppl 257.89 cum. examples 11200, speed 262.19 words/sec, time elapsed 872.45 sec
epoch 1, iter 360, avg. loss 146.17, avg. ppl 262.72 cum. examples 11520, speed 290.56 words/sec, time elapsed 901.35 sec
```

说是要跑4个小时,没法在本地跑,电脑烫的吓人,而且没有GPU,代码是配置好了,colab也不能这么长时间跑,试试别的途径.

参照文档的做法

下面两条指令应该就够了


```
sh run.sh train_local
```

```
sh run.sh test
```

tensorboard serve --logdir=runs可以查看一些日志信息.


正如文档说的,可以看到loss和perplexity在显著的下降,当然,我的电脑也显著的发烫.

loss/train
tag: loss/train



perplexity

perplexity/train
tag: perplexity/train



文档里提出了一个问题:If it's not obvious, think about why we regard h_1^{enc} 和 h_m^{enc} as the 'final hidden state' of the Encoder.

我认为这主要是由于这是一个双向的lstm,1和m都充当了首尾的角色,所以采用了这两个值去做final state.

epoch 1, iter 1950, avg. loss 114.67, avg. ppl 73.41 cum. examples 62400, speed 332.54 words/sec, time elapsed 4841.99 sec

